```
# Стандартный импорт для работы с данными
import numpy as np
import pandas as pd
# Импорт модулей для стандартизации и нормализации
from sklearn.preprocessing import MinMaxScaler,StandardScaler
# Подружаем файл при условии, что он в области видимости
#в рабочей папке
ds = pd.read csv('dataset.csv')
ds.head()
   PassengerId Survived Pclass
0
             1
                       0
                               3
             2
                       1
                               1
1
2
             3
                       1
                               3
3
             4
                       1
                               1
4
             5
                               3
                       0
                                                 Name
                                                          Sex
                                                                Age
SibSp \
                             Braund, Mr. Owen Harris
                                                               22.0
0
                                                         male
1
   Cumings, Mrs. John Bradley (Florence Briggs Th... female 38.0
1
1
2
                              Heikkinen, Miss. Laina female 26.0
0
3
        Futrelle, Mrs. Jacques Heath (Lily May Peel) female 35.0
1
4
                            Allen, Mr. William Henry
                                                         male 35.0
0
   Parch
                    Ticket
                               Fare Cabin Embarked
0
                 A/5 21171
                             7.2500
       0
                                      NaN
                  PC 17599
                            71.2833
                                                  C
1
       0
                                      C85
                                                  S
2
       0 STON/02. 3101282
                             7.9250
                                      NaN
3
                                                  S
       0
                    113803
                            53.1000 C123
                    373450
                             8.0500
       0
                                      NaN
# смотрим имена столбцов
ds.columns
Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age',
'SibSp'
        Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked'],
      dtype='object')
#Если нужно оставить несколько столбцов, вносим их далее через запятую
df = ds[['Survived', 'Sex', 'Age', 'SibSp',
       'Parch', 'Fare']]
df
```

```
Survived
                  Sex
                              SibSp
                                     Parch
                         Age
                                                Fare
0
            0
                 male
                        22.0
                                  1
                                              7.2500
                                         0
1
            1
               female 38.0
                                  1
                                         0
                                             71.2833
2
            1
               female 26.0
                                  0
                                         0
                                             7.9250
3
                                  1
            1
               female 35.0
                                         0
                                             53.1000
4
            0
                 male 35.0
                                  0
                                         0
                                              8.0500
                                . . .
          . . .
                   . . .
                         . . .
                                        . . .
886
            0
                 male 27.0
                                  0
                                             13,0000
                                         0
887
            1
               female 19.0
                                  0
                                         0
                                             30.0000
888
            0
               female
                         NaN
                                  1
                                         2
                                             23.4500
889
            1
                 male
                       26.0
                                  0
                                         0
                                             30.0000
                 male 32.0
890
            0
                                  0
                                         0
                                              7.7500
[891 rows x 6 columns]
# Удаляем строки с проущенными значениями
df = df.dropna()
df
     Survived
                              SibSp
                  Sex
                         Age
                                     Parch
                                                Fare
0
            0
                 male 22.0
                                  1
                                         0
                                              7.2500
1
            1
               female 38.0
                                  1
                                             71.2833
                                         0
2
            1
                                  0
               female 26.0
                                         0
                                             7.9250
3
            1
               female 35.0
                                  1
                                         0
                                             53.1000
4
            0
                                  0
                                              8.0500
                 male 35.0
                                         0
                        39.0
                                             29.1250
885
            0
               female
                                  0
                                         5
            0
886
                 male 27.0
                                  0
                                         0
                                             13.0000
887
            1
               female 19.0
                                  0
                                         0
                                             30.0000
            1
                                         0
889
                 male 26.0
                                  0
                                             30.0000
890
            0
                 male 32.0
                                  0
                                         0
                                              7.7500
[714 rows x 6 columns]
from sklearn.preprocessing import LabelEncoder
# Используем LabelEncoder для кодировки строкового столбца
ncoder = LabelEncoder()
df['Sex'] = ncoder.fit transform(df['Sex'])
df.head()
/usr/local/lib/python3.7/dist-packages/ipykernel launcher.py:3:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user guide/indexing.html#
returning-a-view-versus-a-copy
```

This is separate from the ipykernel package so we can avoid doing imports until

```
Sex
                              Parch
   Survived
                        SibSp
                  Age
                                         Fare
                 22.0
0
                                       7.2500
               1
                            1
                                   0
1
          1
               0 38.0
                            1
                                   0
                                     71.2833
2
                 26.0
                            0
                                      7.9250
          1
               0
                                   0
3
          1
               0 35.0
                            1
                                   0
                                      53.1000
4
          0
                 35.0
                            0
                                       8.0500
               1
                                   0
#Сохраним названия столбцов перед нормализацией, чтобы восстановить в
дальнейшем
columns = df.columns
columns
Index(['Survived', 'Sex', 'Age', 'SibSp', 'Parch', 'Fare'],
dtype='object')
# minmas scaler
mms= MinMaxScaler()
# обучение нормализатора
df = mms.fit transform(np.array(df))
# выыведем 1 строку для оценки результата
df[:1]
                              , 0.27117366, 0.2
array([[0.
                                                      , 0.
        0.01415106]])
# преобразуем обратно в DataFrame
df = pd.DataFrame(data = df, columns = columns)
df.head()
   Survived
            Sex
                           SibSp
                                  Parch
                                              Fare
                       Age
       0.0 1.0 0.271174
0
                              0.2
                                     0.0 0.014151
1
        1.0 0.0 0.472229
                              0.2
                                     0.0 0.139136
2
        1.0 0.0 0.321438
                              0.0
                                     0.0 0.015469
3
        1.0 0.0 0.434531
                              0.2
                                     0.0 0.103644
       0.0 1.0 0.434531
                              0.0
                                    0.0 0.015713
# описательная статистика
```

## # описательная статистика df.describe()

	Survived	Sex	Age	SibSp	Parch
Fare					
count	714.000000	714.000000	714.000000	714.000000	714.000000
714.000000					
mean	0.406162	0.634454	0.367921	0.102521	0.071895
0.0677	19				
std	0.491460	0.481921	0.182540	0.185957	0.142215
0.1032	91				
min	0.000000	0.000000	0.00000	0.00000	0.000000

```
0.000000
25%
         0.000000
                     0.000000
                                 0.247612
                                              0.000000
                                                          0.000000
0.015713
50%
         0.000000
                     1.000000
                                 0.346569
                                              0.000000
                                                          0.000000
0.030726
75%
         1.000000
                     1.000000
                                 0.472229
                                              0.200000
                                                          0.166667
0.065144
                     1.000000
                                 1.000000
                                              1.000000
                                                          1.000000
         1.000000
max
1.000000
#Сумма элементов
df.values.sum()
1178.580104011869
# Округляем до ближайшего целого
round(df.values.sum())
1179
# Стандартизация
std = StandardScaler()
df_s = std.fit_transform(np.array(df))
df s[:1]
array([[-0.82702011, 0.75905134, -0.53037664, 0.52457013, -
0.50589515,
        -0.51897787]])
```