

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ  
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ  
“ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ УПРАВЛЕНИЯ”  
ИНСТИТУТ ПСИХОЛОГИИ И СОЦИОЛОГИИ УПРАВЛЕНИЯ  
КАФЕДРА УПРАВЛЕНИЯ ЗНАНИЯМИ

Специальность: 08.00.13 “Математические и инструментальные методы экономики”

Специализация: “Математические методы”

Форма обучения: Заочная

РЕФЕРАТ

По дисциплине: “Управление знаниями”

Тема реферата: “Характеристика, классификация и практическое применение методов  
машинного обучения”

Выполнил:

аспирант                      Михайлов А.А. \_\_\_\_\_  
(подпись)

Проверил:

к.э.н., доцент              Малыгина О.В. \_\_\_\_\_  
(подпись)

Научный руководитель:

д.э.н., профессор        Лебедев В.В. \_\_\_\_\_  
(подпись)

Москва, 2012

## Оглавление

Введение .....	2
Глава 1. Характеристика и классификация методов машинного обучения .....	3
§ 1.1. Характеристика методов машинного обучения .....	3
§ 1.2. Классификация методов машинного обучения .....	9
Глава 2. Практическое применение методов машинного обучения .....	17
Заключение .....	19
Список использованных источников .....	20

## Введение

Одним из проявлений масштабных, даже тектонических социально-экономических процессов является всемерное удорожание рабочей силы. Сказанное характерно в данный момент развитым странам, но масштабы процессов уже можно считать общемировыми.

Дабы повысить эффективность оплаты дорожающей рабочей силы, избавить работников от рутинных занятий, происходит автоматизация деловых процессов. Представьте, например, чтобы сегодня газированные напитки разливались бы вручную во вручную же созданные стеклянные или пластиковые бутылки. Нонсенс!

Поэтому на передний план в деле все наиболее эффективного использования ресурсов выходит автоматизированный и автоматизированный труд. Но такого рода системами гораздо удобней управлять, если команды можно отдавать на языке как можно более приближенном к языку управляющего, т.е. в данном случае – к человеческому.

Так возникает проблема осмысления и дальнейшего логического описания мыслительных процессов человека. Решением данной проблемы призвана стать дисциплина, которая сейчас называется “искусственным интеллектом”.

Что же касается подраздела искусственного интеллекта, непосредственно посвященному процессами автоматизации таких процессов, как, например, выпуск деловой документации, распознавание речи, обнаружения мошенничества и т.д., то его сегодня принято называть “машинным обучением”.

Следовательно, объектом исследования данной работы будет непосредственно машинное обучение. Предметом же будет сегодняшнее состояние данной дисциплины и то, как ее достижения сегодня используются.

Целью исследования, таким образом, станет описание современного состояния данной дисциплины. Данная цель, в свою очередь, распадается на следующие частные задачи:

- охарактеризовать машинное обучение в его связи с современным положением науки и техники;
- произвести классификацию разновидностей решаемых машинным обучением задач, приложений использования машинного обучения и подходов и методов машинного обучения;
- разобрать пример применения методов машинного обучения на практике.

Данная тема является одной из наиболее математизированных во всем курсе дисциплины “Управление знаниями” в Государственном университете управления. Хотя она и не связана непосредственно с областями диссертационного исследования автора данной работы (которые носят относительно более теоретический характер), в целом ее осмысление и даже практическое применение самих методов машинного обучения имеют большое значение для всего направления 08.00.13 “Математические и инструментальные методы экономики”.

К текущему моменту (весна 2012 г.) написано превеликое множество книг по данному вопросу, среди которых труды отечественных авторов (в т.ч. В.Н. Вапника и А.Я. Червоненкиса) имеют определяющий статус.

# Глава 1. Характеристика и классификация методов машинного обучения

Говоря о характеристике машинного обучения, необходимо сначала обозначить как бы “метафизику” изучаемого явления, его корни и природу. Согласно распространенному определению, машинное обучение (англ. machine learning) – обширный подраздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться.

Поэтому мы начнем данную работу с описания того, чем же является искусственный интеллект. Для этого мы обратимся к уже ставшей классической книге ведущего специалиста в области искусственного интеллекта, эмерит профессора Стэнфордского университета (англ. Stanford University) Нильса Нильсона (англ. Nils J. Nilsson) “Искусственный интеллект”<sup>1</sup> и приведем далее несколько пассажей из нее.

## § 1.1. Характеристика методов машинного обучения

Первый пассаж принадлежит редактору перевода вышеобозначенной книги Сергею Васильевичу Фомину (1917–1975) – выдающемуся советскому математику, в круг интересов которого, помимо прочего, входили исследования в области искусственного интеллекта.

Круг вопросов, объединяемых термином “искусственный интеллект”, достаточно широк и довольно неопределен. В самом общем смысле – это решение “интеллектуальных” задач с помощью автоматических методов, в первую очередь с помощью вычислительных машин. Но какую деятельность следует считать интеллектуальной, а какую нет? Это не вполне ясно. Например, мы привыкли рассматривать решение сложных вычислительных задач как деятельность, несомненно, интеллектуальную. Для специалистов же по искусственному интеллекту большой интерес, пожалуй, представит исследование игры в шашки или “крестики и нолики”, чем, скажем, решение систем дифференциальных уравнений. И для этого есть довольно веские основания. Дело в том, что если для той или иной вычислительной задачи (типа решения уравнений) имеется определенный алгоритм решения, то он достаточно естественно и четко представляется последовательностью отдельных элементарных операций, которая и реализуется в виде соответствующей программы для вычислительной машины. Что же касается таких видов деятельности, как распознавание образов, различного рода игры, решение головоломок и т.д., то для них, напротив, это формальное разбиение процесса поиска решения на отдельные элементарные шаги часто оказывается весьма затруднительным, даже если само их решение и несложно.

Трудность разбиения вычислительных задач на элементарные шаги обычно бывает связана с трудностью формального описания этих задач. Например, человек может отличать кошку от собаки, совершенно не будучи в состоянии дать формальное описание соответствующей процедуры распознавания.

Многие из задач, с которыми нам приходится встречаться в науке, играх, практической Деятельности, в принципе могут быть решены путем перебора некоторого, заведомо конечного числа вариантов и выбора из них варианта, в том или ином смысле наилучшего. Однако в достаточно интересных и содержательных ситуациях такой “полный перебор” неосуществим, поскольку обилие вариантов превосходит возможности любой самой совершенной вычислительной машины. Например, число различных позиций в шахматах, равно как и число

---

<sup>1</sup> Н. Нильсон. Искусственный интеллект. – М.: Издательство “Мир”, 1973. – 272 с.

возможных шахматных партий, состоящих из некоторого ограниченного числа ходов (скажем, не более 40), хотя и конечно, но столь велико, что никакой перебор здесь невозможен. Поэтому в подобных ситуациях возникает вопрос о нахождении возможно более экономных и эффективных способов сокращенного перебора, первоочередного рассмотрения наиболее перспективных путей решения задачи и т.д.

Итак, для проблем искусственного интеллекта существенную роль играет вопрос о формальном описании тех или иных неформально поставленных задач, методах их расчленения на отдельные элементарные шаги, а также об организации различных оптимальных в том или ином смысле процедур перебора вариантов.

<...>

Далее приведем уже пассаж, автором которого является уже непосредственно Нильс Нильсон.

Цель работ по искусственному интеллекту состоит в создании машин, выполняющих такие действия, для которых обычно требуется интеллект человека. В число основных направлений этой области входят автоматические методы решения задач, “понимания” и перевода языков, доказательства теорем и распознавание зрительных образов и речи. Хотя многие из этих задач очень трудны, уже создано несколько программ для вычислительной машины, работающих на уровне, приближающемся к человеческому.

Дальнейшее продвижение в этой области зависит как от развития теории, так и от накопления практических результатов. По мере того как практики будут на основании своего опыта понимать пути построения все более сложных систем обработки информации, будет расширяться запас технических приемов работы. Мы можем ожидать, что развитие технологии цифровых вычислительных машин и совершенствование языков для этих машин (в особенности списковых языков) будет и дальше служить основой для получения необходимых новых практических сведений.

Что же касается теоретических знаний, то здесь имеются сторонники единой теории искусственного интеллекта. Моя точка зрения состоит в том, что искусственный интеллект представляет собой (или скоро будет представлять собой) инженерную дисциплину, поскольку его первоначальной целью является создание конструкций. Поэтому в поисках теории искусственного интеллекта смысла не больше, чем в поисках, скажем, теории гражданского строительства. Вместо единой общей теории имеется ряд теоретических дисциплин, которые сюда относятся и которые должны изучаться теми, кто выбирает искусственный интеллект своей специальностью. К таким дисциплинам относятся математическая логика, структурная лингвистика, теория вычислений, теория информационных структур, теория управления, статистическая теория классификации, теория графов и теория эвристического поиска.

<...>

Решение задач посредством эвристически направляемого, метода проб и ошибок в пространстве возможных решений – доминирующая тема в исследованиях по искусственному интеллекту.

<...>

Многие виды деятельности человека, такие, как решение головоломок, участие в играх, занятия математикой и даже вождение автомобиля, требуют, как это принято считать, участия “интеллекта”. Если бы вычислительные машины могли справляться с деятельностью такого типа, то они (вместе с их программами), вероятно, обладали бы в какой-то степени искусственным интеллектом. Многие специалисты полагают, что в конечном итоге искусственный интеллект вычислительных машин превзойдет интеллект человека, хотя теперь все больше и больше осознается тот факт, что процессы, требуемые для выполнения даже самых обычных для человека задач, неизбежно будут чрезвычайно сложными.

<...>

Решение задач может показаться весьма неясным предметом, и тем не менее на нем концентрируется большая доля исследований по искусственному интеллекту. В самом широком смысле этих слов нахождение решений включает в себя всю вычислительную науку, поскольку всякая вычислительная задача может рассматриваться как задача, решение которой надо найти. Однако для наших целей нужно более узкое определение, которое исключает такие стандартные вычислительные методы, как методы, используемые, скажем, при обращении матрицы 50-го порядка или при решении системы линейных дифференциальных уравнений.

Если мы внимательно рассмотрим методы нахождения решений, изучаемые в исследованиях по искусственному интеллекту, то обнаружим, что в большинстве из них используется понятие поиска путем проб и ошибок. Это значит, что в этих методах задачи решаются посредством поиска решения в пространстве возможных решений. Наша цель состоит в разъяснении наиболее важных методов решения задач с использованием процедур поиска.

Имеются, конечно, и другие важные направления в изучении искусственного интеллекта. Типичные представители тех из них, которым было уделено особое внимание (кроме нахождения решений), следующие:

- обработка сенсорных данных (особенно зрительных образов и речи);
- сложные системы хранения и извлечения информации;
- обработка естественных языков.

К сожалению, никто еще не мог сказать ничего достаточно полезного относительно того, как названные элементы могли бы быть объединены вместе в одном общем “интеллекте” (каком бы то ни было)<sup>2</sup>. В действительности при внимательном анализе становится ясно, что любая из предполагаемых “фундаментальных” компонент интеллектуального поведения содержит, по-видимому, в себе черты других фундаментальных компонент. Так, для сенсорного, восприятия могут потребоваться весьма изощренные способы выбора решения, для которых в свою очередь возникает необходимость в достаточно эффективной системе извлечения информации, опирающейся, возможно, на дополнительный выбор решений и т.д.

Наш опыт работы с этими сложными процессами все еще недостаточен для создания единой теории организации интеллекта. На самом деле в настоящее время<sup>3</sup> нет никаких оснований полагать, что такая теория вообще могла бы существовать. Некоторые исследователи считают, что интеллектуальное поведение может быть получено на вычислительных машинах только

---

<sup>2</sup> На данный момент из источников по этой тематике также не следует какого-либо четкого ответа на данный вопрос. – Прим. авт.

<sup>3</sup> В данном случае – аналогично. – Прим. авт.

посредством комбинирования специализированных программ, каждая из которых содержит множество подходящих к данному случаю решений (или, как их часто называют, “программистских находок”), с возможностью обращения к магазину энциклопедических сведений, содержащему хорошо систематизированные факты. Однако сейчас нам не хотелось бы занимать определенную позицию по этому вопросу. Вместо этого мы опишем те приемы решения задач, которые, по-видимому, имеют достаточно широкую область применения.

После столь исчерпывающего классического описания вопросов искусственного интеллекта, нам кажется возможным приступить к изложению уже непосредственно проблем, связанных с машинным обучением.

Для этого мы опять обратимся к внешним источникам информации: к советской классической литературе по машинному обучению – к книгам Владимира Наумовича Вапника (р. 1936) и Алексея Яковлевича Червоненкиса (р. 1938).

Задаче обучения машин распознаванию образов уже более пятидесяти лет. За это время иные идеи оформились в самостоятельное научное направление, а задача обучения распознаванию образов все еще не обрела формальной постановки, которая удовлетворила бы всех исследователей. И не потому, что ей уделялось мало внимания.

Содержательная (а не формальная) постановка задачи появилась в конце 50-х годов и заключалась в том, чтобы построить машину, способную обучаться классификации ситуаций так же, как это делают живые существа. Такое широкое понимание проблемы привело к возникновению различных направлений исследования. Одни ученые считали главным построение модели процесса восприятия, другие видели основное содержание проблемы в ее утилитарном проявлении – создании алгоритмов обучения распознаванию образов для решения конкретных задач практики, третьи искали в этой задаче постановки новых математических проблем.

Сначала исследование задачи обучения распознаванию образов шло чрезвычайно успешно. Сразу же по всем направлениям удалось сделать значительный шаг: были построены модели, которые на первых порах вполне удовлетворяли исследователей, решено несколько практических задач, которые никак не удавалось решить другими методами, наконец, были доказаны первые теоремы об алгоритмах обучения.

Начало 60-х годов казалось весьма обнадеживающим. Однако время шло, а второй шаг так и не был сделан: усложнение моделей ничего не добавило к объяснению тонких эффектов восприятия, не удалось построить более эффективных алгоритмов распознавания.

С этого момента, пожалуй, впервые стал серьезно проявляться интерес к теории. Теория призвана была выяснить, существуют ли общие принципы обучения, которым должен был бы следовать любой алгоритм, или любая модель процесса восприятия. Словом, как это всегда бывает, к теории обратились тогда, когда выяснилось, что никакие изобретения не позволяют улучшить существующие алгоритмы. От теории ожидали новых принципов, которые позволили бы строить более эффективные алгоритмы обучения. Для построения теории прежде всего надо найти формальную схему, в которую можно было бы вложить задачу обучения распознаванию образов. Это-то и оказалось трудно сделать.

Одни специалисты видели проблему в том, чтобы, используя априорные сведения о свойствах образов, найти такое их описание, при котором отыскание принципа классификации не

составляло бы труда. Другие, напротив, считали выбор системы описания внешним моментом в постановке задачи и видели основную проблему в отыскании правила классификации среди заданного множества возможных правил.

Эти две точки зрения являются диаметрально противоположными. В первом случае постановка должна быть нацелена на выявление общих принципов использования априорной информации при составлении адекватного описания образов. При этом важно, что априорные сведения об образах различной природы разные, а принцип их учета один и тот же.

Во втором случае проблема получения описания выносится за рамки общей постановки и теория обучения машин распознаванию образов сводится к проблеме минимизации риска в специальном классе решающих правил.

По существу, различные точки зрения на постановку задачи распознавания образов определяются ответом на вопрос: возможны ли единые принципы построения адекватного описания образов различной природы или же конструирование языка описания есть каждый раз задача специалистов конкретных областей знаний?

Если да, то выявление этих принципов должно составить основное направление исследования задачи распознавания образов. Основное потому, что такое направление исследований явилось бы и общим и принципиально новым.

Если же нет, то задача обучения распознаванию образов приводится к задаче минимизации среднего риска в специальном классе решающих правил и может рассматриваться как одно из направлений прикладной статистики.

Ответа на этот вопрос до сих пор нет и потому выбор постановки задачи является пока вопросом веры. Большинство исследователей, однако, приняли вторую точку зрения, и под теорией распознавания образов принято сейчас понимать теорию минимизации риска в специальном классе решающих правил.

<...>

Методы минимизации среднего риска являются традиционным предметом исследования теории статистических решений, и поэтому проблема заключается в том, чтобы суметь применить их для соответствующего класса решающих функций. На этом пути существовали известные трудности, но довольно быстро их удалось преодолеть и к середине 60-х годов появилась общая теория обучения распознаванию образов. Эта теория одновременно с удовлетворением принесла и некоторое разочарование. Общий принцип построения алгоритма был чересчур широким: ему удовлетворяло очень много алгоритмов обучения; кроме того, можно было найти регулярным способом (и было показано каким именно) огромное количество конкретных алгоритмов обучения распознаванию образов, которые на практике оказывались ничуть не лучше существующих.

Таким образом, сложилась кризисная ситуация: казалось, что задача обучения распознаванию образов в статистической постановке себя исчерпала.

Вероятно, это было бы действительно так, если бы не одно обстоятельство. Дело в том, что конструктивные методы минимизации среднего риска, разработанные в теории статистических решений, в основном носят асимптотический характер, т.е. метод, минимизирующий величину



среднего риска на основе выборки, считается состоятельным, если с ростом объема выборки с помощью этого метода можно как угодно близко подойти к оптимальному решению. Вот эти-то асимптотически-оптимальные методы минимизации риска и применялись для решения задачи обучения распознаванию образов. На практике же всегда используются выборки ограниченного объема, которые никак нельзя считать настолько большими, чтобы применять асимптотические методы.

Поэтому возникает надежда построить более содержательную теорию применением к нашей специальной задаче минимизации среднего риска, образующей статистическую задачу обучения распознаванию образов, методов минимизации риска на конечных выборках, т.е. построить не асимптотически-оптимальную теорию алгоритмов обучения, а конечно-оптимальную теорию. Но оказалось, что в теории статистических решений нет достаточно общих конструктивных конечно-оптимальных методов минимизации риска. И не потому, что математики не подозревали о существовании такой проблемы; напротив, необходимость создания конструктивных конечно-оптимальных алгоритмов давно была известна, но все попытки построить теорию таких алгоритмов наталкивались на значительные трудности.

Итак, исследование задачи обучения распознаванию образов вывело на нерешенную проблему. Но теперь эта проблема стоит не во всем объеме, а лишь для специального класса задач. Конечно-оптимальная теория алгоритмов обучения распознаванию образов еще не построена. Однако вне зависимости от того, насколько удачными окажутся попытки построить такую теорию, идея создания конечно-оптимальных методов минимизации риска для специального класса решающих правил уже принесла свои плоды: были найдены новые достаточно общие процедуры поиска оптимальных решений.

Что же сейчас составляет статистическую теорию обучения распознаванию образов? Вероятно, правильно было бы видеть в задаче обучения распознаванию образов три линии развития.

Первая линия связана со становлением задачи. В ней можно проследить, как из физиологической модели восприятия возникают алгоритмы опознания образов, как задача обучения формулируется в четких математических терминах, как она вливается в традиционные задачи математической статистики, какие новые идеи она порождает, как способствует решению задач практики.

Вторая линия отражает влияние задачи обучения распознаванию образов на развитие аппарата математической статистики. Здесь можно проследить, как сначала использовались известные методы статистики, как затем образовывались новые понятия, и, наконец, можно увидеть влияние этих новых идей на развитие традиционных направлений исследований в статистике.

Третья линия отражает развитие конструктивных идей построения алгоритмов. Сначала это были некоторые эвристические процедуры, единственным обоснованием которых была ссылка на аналогию с физиологическими моделями восприятия, затем это были различные методы построения разделяющих поверхностей и, наконец, это — методы выбора экстремальных подпространств и построения на них различных решающих правил.

## **§ 1.2. Классификация методов машинного обучения**

После столь исчерпывающего изложения основных положений и принципов машинного обучения, приступим к упорядочению знаний, касающихся этой дисциплины.

Различают два типа машинного обучения. Обучение по прецедентам, или индуктивное обучение, основано на выявлении общих закономерностей по частным эмпирическим данным. Дедуктивное обучение предполагает формализацию знаний экспертов и их перенос в компьютер в виде базы знаний. Дедуктивное обучение принято относить к области экспертных систем, поэтому термины машинное обучение и обучение по прецедентам можно считать синонимами.

Машинное обучение находится на стыке математической статистики, методов оптимизации и классических математических дисциплин, но имеет также и собственную специфику, связанную с проблемами вычислительной эффективности и переобучения. Многие методы индуктивного обучения разрабатывались как альтернатива классическим статистическим подходам. Многие методы тесно связаны с извлечением информации и интеллектуальным анализом данных (англ. data mining).

Наиболее теоретические разделы машинного обучения объединены в отдельное направление, теорию вычислительного обучения (англ. computational learning theory, COLT).

Машинное обучение – не только математическая, но и практическая, инженерная дисциплина. Чистая теория, как правило, не приводит сразу к методам и алгоритмам, применимым на практике. Чтобы заставить их хорошо работать, приходится изобретать дополнительные эвристики, компенсирующие несоответствие сделанных в теории предположений условиям реальных задач. Практически ни одно исследование в машинном обучении не обходится без эксперимента на модельных или реальных данных, подтверждающего практическую работоспособность метода.

### **Общая постановка задачи обучения по прецедентам**

Дано конечное множество прецедентов (объектов, ситуаций), по каждому из которых собраны (измерены) некоторые данные. Данные о прецеденте называют также его описанием. Совокупность всех имеющихся описаний прецедентов называется обучающей выборкой. Требуется по этим частным данным выявить общие зависимости, закономерности, взаимосвязи, присущие не только этой конкретной выборке, но вообще всем прецедентам, в том числе тем, которые ещё не наблюдались. Говорят также о восстановлении зависимостей по эмпирическим данным – этот термин был введён в работах Вапника и Червоненкиса.

Наиболее распространённым способом описания прецедентов является признаковое описание. Фиксируется совокупность  $n$  показателей, измеряемых у всех прецедентов. Если все  $n$  показателей числовые, то признаковые описания представляют собой числовые векторы размерности  $n$ . Возможны и более сложные случаи, когда прецеденты описываются временными рядами или сигналами, изображениями, видеорядами, текстами, попарными отношениями сходства или интенсивности взаимодействия, и т.д.

Для решения задачи обучения по прецедентам в первую очередь фиксируется модель восстанавливаемой зависимости. Затем вводится функционал качества, значение которого показывает, насколько хорошо модель описывает наблюдаемые данные. Алгоритм обучения

(англ. learning algorithm) ищет такой набор параметров модели, при котором функционал качества на заданной обучающей выборке принимает оптимальное значение. Процесс настройки (англ. fitting) модели по выборке данных в большинстве случаев сводится к применению численных методов оптимизации.

Замечание о терминологии. В зарубежных публикациях термин algorithm употребляется только в указанном выше смысле, то есть это вычислительная процедура, которая по обучающей выборке производит настройку модели. Выходом алгоритма обучения является функция, аппроксимирующая неизвестную (восстанавливаемую) зависимость. В задачах классификации аппроксимирующую функцию принято называть классификатором (англ. classifier), концептом (англ. concept) или гипотезой (англ. hypothesis); в задачах восстановления регрессии – функцией регрессии; иногда просто функцией. В русскоязычной литературе аппроксимирующую функцию также называют алгоритмом, подчёркивая, что и она должна допускать эффективную компьютерную реализацию.

## **Типология задач обучения по прецедентам**

### **1. Основные стандартные типы задач**

1.1. Обучение с учителем (англ. supervised learning) – наиболее распространённый случай. Каждый прецедент представляет собой пару “объект, ответ”. Требуется найти функциональную зависимость ответов от описаний объектов и построить алгоритм, принимающий на входе описание объекта и выдающий на выходе ответ. Функционал качества обычно определяется как средняя ошибка ответов, выданных алгоритмом, по всем объектам выборки.

- Задача классификации (англ. classification) отличается тем, что множество допустимых ответов конечно. Их называют метками классов (англ. class label). Класс – это множество всех объектов с данным значением метки.
- Задача регрессии (англ. regression) отличается тем, что допустимым ответом является действительное число или числовой вектор.
- Задача ранжирования (англ. learning to rank) отличается тем, что ответы надо получить сразу на множестве объектов, после чего отсортировать их по значениям ответов. Может сводиться к задачам классификации или регрессии. Часто применяется в информационном поиске и анализе текстов.
- Задача прогнозирования (англ. forecasting) отличается тем, что объектами являются отрезки временных рядов, обрывающиеся в тот момент, когда требуется сделать прогноз на будущее. Для решения задач прогнозирования часто удаётся приспособить методы регрессии или классификации, причём во втором случае речь идёт скорее о задачах принятия решений.

1.2. Обучение без учителя (англ. unsupervised learning). В этом случае ответы не задаются, и требуется искать зависимости между объектами.

- Задача кластеризации (англ. clustering) заключается в том, чтобы сгруппировать объекты в кластеры, используя данные о попарном сходстве объектов. Функционалы качества могут определяться по-разному, например, как отношение средних межкластерных и внутрикластерных расстояний.
- Задача поиска ассоциативных правил (англ. association rules learning). Исходные данные представляются в виде признаковых описаний. Требуется найти такие наборы признаков,

и такие значения этих признаков, которые особенно часто (неслучайно часто) встречаются в признаковых описаниях объектов.

- Задача фильтрации выбросов (англ. outliers detection) – обнаружение в обучающей выборке небольшого числа нетипичных объектов. В некоторых приложениях их поиск является самоцелью (например, обнаружение мошенничества). В других приложениях эти объекты являются следствием ошибок в данных или неточности модели, то есть шумом, мешающим настраивать модель, и должны быть удалены из выборки, см. также робастные методы и одноклассовая классификация.
- Задача построения доверительной области (англ. quantile estimation) – области минимального объёма с достаточно гладкой границей, содержащей заданную долю выборки.
- Задача сокращения размерности (англ. dimensionality reduction) заключается в том, чтобы по исходным признакам с помощью некоторых функций преобразования перейти к наименьшему числу новых признаков, не потеряв при этом никакой существенной информации об объектах выборки. В классе линейных преобразований наиболее известным примером является метод главных компонент.
- Задача заполнения пропущенных значений (англ. missing values) – замена недостающих значений в матрице объекты-признаки их прогнозными значениями.

1.3. Частичное обучение (англ. semi-supervised learning) занимает промежуточное положение между обучением с учителем и без учителя. Каждый прецедент представляет собой пару “объект, ответ”, но ответы известны только на части прецедентов. Пример прикладной задачи – автоматическая рубрикация большого количества текстов при условии, что некоторые из них уже отнесены к каким-то рубрикам.

1.4. Трансдуктивное обучение (англ. transductive learning). Дана конечная обучающая выборка прецедентов. Требуется по этим частным данным сделать предсказания относительно других частных данных – тестовой выборки. В отличие от стандартной постановки, здесь не требуется выявлять общую закономерность, поскольку известно, что новых тестовых прецедентов не будет. С другой стороны, появляется возможность улучшить качество предсказаний за счёт анализа всей тестовой выборки целиком, например, путём её кластеризации. Во многих приложениях трансдуктивное обучение практически не отличается от частичного обучения.

1.5. Обучение с подкреплением (англ. reinforcement learning). Роль объектов играют пары “ситуация, принятое решение”, ответами являются значения функционала качества, характеризующего правильность принятых решений (реакцию среды). Как и в задачах прогнозирования, здесь существенную роль играет фактор времени. Примеры прикладных задач: формирование инвестиционных стратегий, автоматическое управление технологическими процессами, самообучение роботов, и т.д.

1.6. Динамическое обучение (англ. online learning) может быть как обучением с учителем, так и без учителя. Специфика в том, что прецеденты поступают потоком. Требуется немедленно принимать решение по каждому прецеденту и одновременно доучивать модель зависимости с учётом новых прецедентов. Как и в задачах прогнозирования, здесь существенную роль играет фактор времени.

1.7. Активное обучение (англ. active learning) отличается тем, что обучаемый имеет возможность самостоятельно назначать следующий прецедент, который станет известен. См. также Планирование экспериментов.

1.8. Метаобучение (англ. meta-learning или англ. learning-to-learn) отличается тем, что прецедентами являются ранее решённые задачи обучения. Требуется определить, какие из используемых в них эвристик работают более эффективно. Конечная цель – обеспечить постоянное автоматическое совершенствование алгоритма обучения с течением времени.

- Многозадачное обучение (англ. multi-task learning). Набор взаимосвязанных или схожих задач обучения решается одновременно, с помощью различных алгоритмов обучения, имеющих схожее внутренне представление. Информация о сходстве задач между собой позволяет более эффективно совершенствовать алгоритм обучения и повышать качество решения основной задачи.
- Индуктивный перенос (англ. inductive transfer). Опыт решения отдельных частных задач обучения по прецедентам переносится на решение последующих частных задач обучения. Для формализации и сохранения этого опыта применяются реляционные или иерархические структуры представления знаний.
- Иногда к метаобучению ошибочно относят построение алгоритмических композиций, в частности, бустинг; однако в композициях несколько алгоритмов решают одну и ту же задачу, тогда как метаобучение предполагает, что решается много разных задач.

## 2. Специфические прикладные задачи

Некоторые задачи, возникающие в прикладных областях, имеют черты сразу нескольких стандартных типов задач обучения, поэтому их трудно однозначно отнести к какому-то одному типу.

2.1. Формирование инвестиционного портфеля (англ. portfolio selection) – это динамическое обучение с подкреплением, в котором очень важен отбор информативных признаков. Роль признаков играют финансовые инструменты. Состав оптимального набора признаков (портфеля) может изменяться со временем. Функционалом качества является долгосрочная прибыль от инвестирования в данную стратегию управления портфелем.

2.2. Коллаборативная фильтрация (англ. collaborative filtering) – это прогнозирование предпочтений пользователей на основе их прежних предпочтений и предпочтений схожих пользователей. Применяются элементы классификации, кластеризации и восполнения пропущенных данных. См. также Персонализация и Анализ клиентских сред.

## Приложения

Целью машинного обучения является частичная или полная автоматизация решения сложных профессиональных задач в самых разных областях человеческой деятельности. Машинное обучение имеет широкий спектр приложений:

- приложения в биоинформатике;
- приложения в медицине:
  - медицинская диагностика;
- приложения в геологии и геофизике;
- приложения в социологии;

- приложения в экономике:
  - кредитный скоринг (англ. credit scoring);
  - предсказание ухода клиентов (англ. churn prediction);
  - обнаружение мошенничества (англ. fraud detection);
  - биржевой технический анализ (англ. technical analysis);
  - биржевой надзор (англ. market surveillance);
- приложения в технике:
  - техническая диагностика;
  - робототехника;
  - компьютерное зрение;
  - распознавание речи;
- приложения в офисной автоматизации:
  - распознавание текста;
  - обнаружение спама;
  - категоризация документов;
  - распознавание рукописного ввода.

Сфера применений машинного обучения постоянно расширяется. Повсеместная информатизация приводит к накоплению огромных объёмов данных в науке, производстве, бизнесе, транспорте, здравоохранении. Возникающие при этом задачи прогнозирования, управления и принятия решений часто сводятся к обучению по прецедентам. Раньше, когда таких данных не было, эти задачи либо вообще не ставились, либо решались совершенно другими методами.

## **Подходы и методы**

Подход к задачам обучения – это концепция, парадигма, точка зрения на процесс обучения, приводящая к набору базовых предположений, гипотез, эвристик, на основе которых строится модель, функционал качества и методы его оптимизации.

Разделение методов “по подходам” довольно условно. Разные подходы могут приводить к одной и той же модели, но разным методам её обучения. В некоторых случаях эти методы отличаются очень сильно, в других – совсем немного и “плавно трансформируются” друг в друга путём незначительных модификаций.

### **1. Статистическая классификация**

В статистике решение задач классификации принято называть дискриминантным анализом.

Байесовская теория классификации основана на применении оптимального байесовского классификатора и оценивании плотностей распределения классов по обучающей выборке. Различные методы оценивания плотности порождают большое разнообразие байесовских классификаторов. Среди них можно выделить три группы методов:

#### **1.1. Параметрическое оценивание плотности:**

- квадратичный дискриминант;
- линейный дискриминант Фишера;

#### **1.2. Непараметрическое оценивание плотности:**

- метод парзеновского окна;

### 1.3. Оценивание плотности как смеси параметрических плотностей:

- разделение смеси распределений, EM-алгоритм;
- метод радиальных базисных функций.

Несколько особняком стоит наивный байесовский классификатор, который может быть как параметрическим, так и непараметрическим. Он основан на нереалистичном предположении о статистической независимости признаков. Благодаря этому метод чрезвычайно прост.

Другие теоретико-вероятностные и статистические подходы:

- скрытая марковская цепь;
- байесовская сеть.

## 2. Классификация на основе сходства

Метрические алгоритмы классификации применяются в тех задачах, где удаётся естественным образом задавать объекты не их признаковыми описаниями, а матрицей попарных расстояний между объектами. Классификация объектов по их сходству основана на гипотезе компактности, которая гласит, что в “хорошей задаче” схожие объекты чаще лежат в одном классе, чем в разных.

Метрические алгоритмы относятся к методам рассуждения на основе прецедентов (англ. Case Based Reasoning, CBR). Здесь действительно можно говорить о “рассуждениях”, так как на вопрос “почему объект  $x$  был отнесён к классу  $y$ ?” алгоритм может дать понятный эксперту ответ: “потому, что имеются прецеденты – схожие с ним объекты, принадлежащие классу  $y$ ”, и предъявить список этих прецедентов.

Наиболее известные метрические алгоритмы классификации:

- метод ближайших соседей;
- метод парзеновского окна;
- метод потенциальных функций;
- метод радиальных базисных функций;
- отбор эталонных объектов.

## 3. Классификация на основе разделимости

Большая группа методов классификации основана на явном построении разделяющей поверхности в пространстве объектов. Из них чаще всех применяются Линейные классификаторы:

- линейный дискриминант Фишера;
- однослойный персептрон;
- логистическая регрессия;
- машина опорных векторов (метод опорных векторов; англ. SVM).

## 4. Нейронные сети

Нейронные сети основаны на принципе коннективизма – в них соединяется большое количество относительно простых элементов, а обучение сводится к построению оптимальной структуры связей и настройке параметров связей.

Нейронные сети:

- персептрон;
- однослойный персептрон;
- многослойный персептрон;
- метод стохастического градиента;
- метод обратного распространения ошибки (англ. backpropagation или backprop);
- нейронная сеть Кохонена;
- гибридная сеть встречного распространения;
- сеть радиальных базисных функций;
- оптимальное усечение сети (англ. optimal brain damage или OBD).

#### 5. Индукция правил (поиск закономерностей)

Логические алгоритмы классификации представляют собой композиции простых, легко интерпретируемых правил.

Индукция правил:

- решающее дерево;
- решающий список;
- решающий лес;
- тестовый алгоритм;
- алгоритм вычисления оценок;
- дерево регрессии;
- ассоциативные правила (правила ассоциации).

#### 6. Кластеризация

Кластеризация:

- графовые алгоритмы кластеризации;
- статистические алгоритмы кластеризации;
- алгоритм ФОРЕЛЬ;
- алгоритм  $k$  средних (англ.  $k$ -means);
- иерархическая кластеризация;
- ко-кластеризация;
- нейронная сеть Кохонена;
- ансамбль кластеризаторов.

#### 7. Регрессия

Регрессия:

- линейная регрессия;
- нелинейная регрессия;



- векторная регрессия;
- логистическая регрессия.

## 8. Алгоритмические композиции

Алгоритмические композиции:

- взвешенное голосование;
- бустинг;
- бэггинг;
- метод случайных подпространств;
- метод комитетов;
- смесь экспертов.

## 9. Сокращение размерности

Сокращение размерности:

- селекция признаков (отбор признаков);
- метод главных компонент;
- метод независимых компонент;
- многомерное шкалирование.

## 10. Выбор модели

Выбор модели:

- минимизация эмпирического риска;
- структурная минимизация риска;
- минимум длины описания;
- критерий Акаике (англ. AIC);
- байесовский информационный критерий (англ. BIC);
- скользящий контроль;
- извлечение признаков;
- метод группового учёта аргументов (МГУА, самоорганизация моделей);
- случайный поиск с адаптацией;
- генетический алгоритм.

## 11. Байесовский вывод

Байесовский вывод:

- байесовский вывод;
- байесовский информационный критерий (англ. BIC);
- метод релевантных векторов (англ. RVM);
- байесовская сеть.

## Глава 2. Практическое применение методов машинного обучения

Таким образом мы подошли к описанию практического применения методов машинного обучения. Для этого мы обратимся к примеру компании “Яндекс”<sup>4</sup>.

Сейчас уже сложно придумать такой запрос, по которому находится меньше десятка страниц. А по многим запросам результатов поиска – миллионы. И со временем их становится все больше – интернет очень быстро растет. Поэтому поисковой системе уже недостаточно просто показать все страницы со словами из запроса – чтобы найти подходящий ответ, человеку придется листать десятки страниц с результатами поиска. Поисковая система должна расположить найденные страницы в нужном порядке – так, чтобы сверху оказались наиболее подходящие пользователю (наиболее релевантные). Этот процесс – упорядочивание результатов поиска в соответствии с запросом пользователя – называется ранжированием. Именно ранжирование определяет качество поиска – то есть качество ответа на вопрос, заданный в поисковой строке.

Каждый день Яндекс отвечает больше, чем на сто миллионов запросов. Около четверти из них – неповторяющиеся. Поэтому невозможно написать для поисковой системы такую программу, в которой предусмотрен каждый запрос, и для каждого запроса известен лучший ответ. Поисковая система должна уметь принимать решения самостоятельно, то есть – сама выбирать из миллионов документов тот, который лучше всего отвечает пользователю. Для этого нужно научить ее обучаться.

Задача научить машину обучаться существует не только в поисковых технологиях. Без машинного обучения невозможно, например, распознавать рукописный текст или речь. <...> В результате машинного обучения компьютер может демонстрировать поведение, которое в него не было явно заложено.

Поисковая система должна научиться строить правило, которое определяет для каждого запроса, какая страница является хорошим ответом на него, а какая – нет. Для этого поисковая машина анализирует свойства веб-страниц и поисковых запросов. У всех страниц есть какие-то признаки. Некоторые из них – статические – связаны с самой страницей, например, количество ссылок на эту страницу в интернете. Некоторые признаки – динамические – связаны одновременно с запросом и страницей – например, присутствие в тексте страницы слов запроса, их количество и расположение.

У поискового запроса тоже есть свойства, например, геоинформация – это означает, что для хорошего ответа на этот запрос нужно учитывать регион, из которого он был задан. Свойства запроса и страницы, которые важны для ранжирования и которые можно измерить числами, называются факторами ранжирования. Для точного поиска важно учитывать очень много разных факторов.

### Асессоры

Кроме факторов ранжирования поисковой системе необходимы образцы – запросы и страницы, которые люди считают подходящими ответами на эти запросы. Оценкой того, насколько та или иная страница подходит для ответа на тот или иной запрос, занимаются специалисты – асессоры. Они берут поисковые запросы и документы, которые поиск находит по этим запросам, и оценивают, насколько хорошо найденный документ отвечает на заданный запрос. Из запросов и хороших ответов составляется обучающая выборка. Она должна содержать

---

<sup>4</sup> <http://company.yandex.ru/technologies/learning/>

самые разные запросы, причем в тех же пропорциях, в которых их задают пользователи. На обучающей выборке поисковая система устанавливает зависимость между страницами, которые ассессоры посчитали релевантными запросам, и свойствами этих страниц. После этого она может подобрать оптимальную формулу ранжирования – которая показывает релевантные запросу сайты среди первых результатов поиска.

На примере это выглядит так. Допустим, мы хотим научить машину выбирать самые вкусные яблоки. Ассессоры в этом случае получают ящик яблок, пробуют их все и раскладывают на две кучи, вкусные – в одну, невкусные – в другую. Из разных яблок составляется обучающая выборка. Машина пробовать яблоки не может, но она может проанализировать их свойства. Например – какого они размера, какого цвета, сколько сахара содержат, твердые или мягкие, с листиком или без. На обучающей выборке машина учится выбирать самые вкусные яблоки – с оптимальным сочетанием размера, цвета, кислоты и твердости. При этом могут возникать какие-то ошибки. Например, поскольку машина ничего не знает про червяков, среди выбранных яблок могут оказаться червивые. Чтобы ошибок было меньше, нужно учитывать больше признаков яблок.

### **Переобучение**

В поисковых технологиях машинное обучение применяется с начала 2000-х годов. Разные поисковые системы используют разные модели. Одна из проблем, которые возникают при машинном обучении – переобучение. Переобучившаяся машина похожа на студента, который перезанимался – например, прочитал очень много книжек перед экзаменом по психологии. Он мало общается с живыми людьми и пытается объяснить простые поступки слишком сложными моделями поведения. И из-за этого поведение друзей для него всегда неожиданно.

Как это выглядит: когда компьютер оперирует большим количеством факторов (в нашем случае это – признаки страниц и запросов), а размер обучающей выборки (оценок ассессоров) не очень велик, компьютер начинает искать и находить несуществующие закономерности. Например, среди всех оцененных страниц могут оказаться две с какой-то сложной комбинацией факторов, например, с размером 2 кб, фоном фиолетового цвета и текстом, который начинается на букву “я”. И обе эти страницы окажутся релевантными запросу [яблоко]. Компьютер начнет считать эту случайную комбинацию факторов важным признаком релевантности запросу [яблоко]. При этом все важные документы про яблоки, которые такой комбинацией факторов не обладают, покажутся ему менее релевантными.

Для построения формулы ранжирования Яндекс использует собственный метод машинного обучения – Матрикснет. Он устойчив к переобучению.

## **Заключение**

В ходе данной работы были решены следующие задачи:

- была дана характеристика машинному обучению в его связи с современным положением науки и техники;
- была произведена классификация разновидностей решаемых машинным обучением задач, приложений использования машинного обучения и подходов и методов машинного обучения;
- был разобран пример компании “Яндекс” применения методов машинного обучения на практике.

Таким образом, можно считать, что цель данной работы – описать современное состояние машинного обучения – была достигнута.

В заключение остается сказать, что данная проблема является одной из важнейших для дальнейшего развития информационных технологий и их приложениях к деловой практике и что от успехов в ее решении зависит будущее, например, такого института, как документооборот – он вполне себе может стать обезчеловеченным (насколько это вообще возможно).

## **Список использованных источников**

1. Айвазян С.А., Бухштабер В.М., Енюков И.С., Мешалкин Л.Д. Прикладная статистика: Классификация и снижение размерности. – М.: “Финансы и статистика”, 1989. – 608 с.
2. Айвазян С.А., Енюков И.С., Мешалкин Л.Д. Прикладная статистика: Исследование зависимостей. – М.: “Финансы и статистика”, 1984. – 488 с.
3. Айвазян С.А., Енюков И.С., Мешалкин Л.Д. Прикладная статистика: Основы моделирования и первичная обработка данных. – М.: “Финансы и статистика”, 1982. – 472 с.
4. Айвазян С.А., Мхитарян В.С. Прикладная статистика и основы эконометрики. - М.: ЮНИТИ, 1998. - 1005 с.
5. Восстановление зависимостей по эмпирическим данным. Вапник В.Н. Главная редакция физико-математической литературы издательства “Наука”, М., 1979, 447 стр.
6. Теория распознавания образов (статистические проблемы обучения). В.Н. Вапник, А.Я. Червоненкис. Издательство “Наука”, Главная редакция физико-математической литературы, М., 1974, 416 стр.
7. Н. Нильсон. Искусственный интеллект. – М.: Издательство “Мир”, 1973. – 272 с.
8. <http://company.yandex.ru/technologies/learning/>
9. [http://www.machinelearning.ru/wiki/index.php?title=%D0%9C%D0%B0%D1%88%D0%B8%D0%BD%D0%BD%D0%BE%D0%B5\\_%D0%BE%D0%B1%D1%83%D1%87%D0%B5%D0%BD%D0%B8%D0%B5](http://www.machinelearning.ru/wiki/index.php?title=%D0%9C%D0%B0%D1%88%D0%B8%D0%BD%D0%BD%D0%BE%D0%B5_%D0%BE%D0%B1%D1%83%D1%87%D0%B5%D0%BD%D0%B8%D0%B5)